

VLười - Gói ôn tập

AI & LLM Foundation (Day 1)

29 slides | 369 học viên hỏi | 3 chủ đề

Lý thuyết trọng tâm

- AI, ML, Deep Learning, GenAI, LLM — nằm ở đâu trong cùng một hệ?. AI là chiếc ô lớn nhất bao gồm mọi hệ thống thông minh. ML là học từ dữ liệu, DL là mạng nơ-ron nhiều tầng, GenAI sinh nội dung mới, LLM là model nền chuyên ngôn ngữ. LLM không phải toàn bộ AI nhưng là tầng nền của hầu hết trải nghiệm AI hiện nay. [trang 3]
- Ba nhóm AI chính: phân loại · sinh nội dung · hành động. Discriminative AI giỏi phân loại, dự đoán. Generative AI sinh ra thứ mới. Agentic AI nhận mục tiêu rồi tự làm nhiều bước. LLM là engine chung của cả Generative lẫn Agentic. [trang 4]
- Lịch sử AI 70 năm: từ hệ chuyên gia đến Transformer và ChatGPT. 1980: Hệ chuyên gia (expert system) tập trung giải tốt một miền hẹp. 2009: Fei-Fei Li và ImageNet — dữ liệu lớn đánh bại thuật toán khôn. 2017: Transformer cho phép mỗi từ nhìn sang các từ quan trọng khác. 2022: ChatGPT đưa LLM đến đại chúng. [trang 5, 6, 7, 8]
- Bên trong LLM: Token, Context, Attention. Token là mảnh chữ model đọc, mọi thứ đều quy ra token và có giá. Context là bàn làm việc có hạn, model chỉ nhìn được lượng chữ nhất định. Attention cho phép mỗi token chủ động nhìn lại các token khác, chấm điểm mức độ liên quan. [trang 11, 12, 13, 14]

Cả lớp thường hỏi

Phân biệt AI, ML, DL, GenAI, LLM

Điểm dễ nhầm: Nhiều học viên nhầm lẫn LLM là toàn bộ AI, hoặc không phân biệt được GenAI và LLM.

Cách hiểu đúng: LLM là một phần của GenAI, GenAI là một phần của Deep Learning, Deep Learning là một phần của Machine Learning, Machine Learning là một phần của AI. LLM là model nền chuyên ngôn ngữ, không phải toàn bộ AI. (1 học viên, trang 3)

Cơ chế Attention và quản lý Context

Điểm dễ nhầm: Học viên thắc mắc tại sao model có thể 'quên' thông tin ở giữa context dài, và làm thế nào để tối ưu prompt.

Cách hiểu đúng: Attention có hạn và có điểm mù. Đặt thông tin quan trọng ở đầu hoặc cuối prompt, tránh để ở giữa. Context càng dài càng tốn token và chậm. (1 học viên, trang 14, 15, 16)

Token và chi phí

Điểm dễ nhầm: Học viên không hiểu tại sao tiếng Việt, code, JSON tốn nhiều token hơn tiếng Anh.

Cách hiểu đúng: Tokenizer cắt văn bản thành mảnh nhỏ. Tiếng Việt có dấu thanh, code có ký tự đặc biệt nên bị cắt nhỏ hơn, dẫn đến nhiều token hơn. Mỗi token đều có giá. (1 học viên, trang 13)

Câu tự kiểm tra

1. LLM thuộc nhóm AI nào?

- A. Discriminative AI
- B. Generative AI
- C. Agentic AI

D. Cả Generative và Agentic

Đáp án: D. LLM là engine chung của cả Generative AI (sinh văn bản) và Agentic AI (lập kế hoạch, dùng công cụ).
[trang 4]

2. Sự kiện nào đánh dấu bước ngoặt đưa Transformer trở thành nền tảng cho LLM?

- A. 1980: Hệ chuyên gia
- B. 2009: ImageNet
- C. 2017: Transformer
- D. 2022: ChatGPT

Đáp án: C. Transformer ra đời năm 2017 cho phép mỗi từ nhìn sang các từ quan trọng khác, trở thành nền móng cho GPT, BERT và các LLM sau này. [trang 8]

3. Tại sao model có thể 'quên' thông tin ở giữa một prompt rất dài?

- A. Vì model chỉ nhớ được 100 token
- B. Vì attention có điểm mù ở giữa context
- C. Vì model không có cơ chế attention
- D. Vì tokenizer bỏ qua phần giữa

Đáp án: B. Attention có hạn và có điểm mù: thông tin ở giữa context dễ bị bỏ sót hơn so với đầu hoặc cuối. [trang 14, 16]